SBC Computing Reviews, 2026, XX:1
ISSN: 2966-3938 • doi: 10.5753/rocs.2026.XXXXXX
This work is licensed under a Creative Commons Attribution 4.0 International License.

Proposta de Portfólio

Assistente Conversacional de Business Intelligence via Aplicativo de Mensagens com Agentes de IA

Conversational BI Assistant via Messaging App with AI Agents

Arthur Hassuma [Católica SC | *arthur.hassuma@catolicasc.edu.br*]

Curso de Engenharia de Software, Centro Universitário Católica de Santa Catarina, Jaraguá do Sul, SC, Brasil.

Resumo. Este trabalho propõe o desenvolvimento de um assistente conversacional de Business Intelligence (BI) acessível via aplicativo de mensagens, voltado a gestores de empresas de serviços B2B. A solução emprega um agente de IA com arquitetura de *function calling* e Large Language Models (LLMs), capaz de interpretar perguntas em linguagem natural, gerar consultas SQL automaticamente e retornar respostas humanizadas sobre indicadores de negócio em tempo real. O sistema é validado sobre base de dados sintética modelada a partir do contexto operacional da empresa parceira Galvitech, cobrindo vendas, faturamento, pedidos e indicadores operacionais. A hipótese central é que o agente atinge *execution accuracy* superior a 70% e tempo de resposta inferior ao acesso manual a dashboards, democratizando o consumo de dados analíticos para perfis não técnicos.

Abstract. This work proposes the development of a conversational Business Intelligence (BI) assistant accessible via a messaging application, aimed at managers of B2B service companies. The solution employs an AI agent with a function calling architecture and Large Language Models (LLMs), capable of interpreting natural language questions, automatically generating SQL queries, and returning humanized responses about business indicators in real time. The system is validated on a synthetic database modeled from the operational context of the partner company Galvitech, covering sales, revenue, orders, and operational indicators. The central hypothesis is that the agent achieves execution accuracy above 70% and response time lower than manual dashboard access, democratizing analytical data consumption for non-technical profiles.

Palavras-chave: Inteligência Artificial, Agentes de IA, Text-to-SQL, Business Intelligence, Aplicativo de Mensagens, LLM

Keywords: Artificial Intelligence, AI Agents, Text-to-SQL, Business Intelligence, Messaging Application, LLM

1 Introdução

Decisões gerenciais dependem cada vez mais de dados operacionais atualizados. Ferramentas de BI tradicionais — dashboards estáticos, relatórios agendados — exigem que o gestor saiba onde buscar a informação, interprete gráficos e domine a navegação na plataforma [Golfarelli and Rizzi, 2009]. Esse atrito é especialmente crítico em empresas de tecnologia e serviços B2B, onde indicadores de projetos, faturamento e desempenho operacional precisam estar disponíveis para tomada de decisão imediata — inclusive fora do horário comercial, quando o acesso a analistas ou a ferramentas corporativas é limitado.

Problema de Pesquisa: Gestores de empresas de serviços B2B dependem de analistas ou de acesso manual a dashboards para obter informações estratégicas, introduzindo latência na tomada de decisão e criando gargalo em equipes técnicas. Em que medida um agente de IA conversacional, integrado a um aplicativo de mensagens e baseado em LLMs com *function calling* e Text-to-SQL, é capaz de fornecer respostas precisas sobre indicadores de BI a gestores não técnicos, reduzindo o tempo de acesso à informação frente ao uso de dashboards convencionais?

Hipótese: Um agente com LLM, equipado com ferramentas de consulta ao banco de dados via *function calling* e instruído com o esquema e o vocabulário do domínio B2B, atingirá *execution accuracy* superior a 70% e tempo de resposta inferior ao acesso manual a dashboards [Guo *et al*., 2019; Wang *et al*., 2024].

Objetivos: O objetivo geral é desenvolver e avaliar um assistente conversacional de BI integrado a um aplicativo de mensagens, baseado em agente de IA com LLM e *function calling*, validado sobre base de dados sintética. Os objetivos específicos são: (1) modelar base de dados sintética B2B em PostgreSQL; (2) implementar o agente com pipeline Text-to-SQL e *function calling* [Wang *et al*., 2024]; (3) integrar o agente ao aplicativo de mensagens [Mohammadjafari *et al*., 2024]; (4) avaliar *execution accuracy*, correção semântica e latência [Guo *et al*., 2019; Yu *et al*., 2018]; e (5) validar qualitativamente com a Galvitech.

Estruturação do Texto: O documento está organizado em: Trabalhos Relacionados (Seção 2), Metodologia com proposta, inovação e arquitetura (Seção 3), Resultados Esperados (Seção 4), Discussões e Conclusões (Seção 5) e Apêndice com tabela comparativa e cronograma (Seção 6).

2 Trabalhos Relacionados

A literatura recente sobre Text-to-SQL com LLMs oferece bases técnicas sólidas para este trabalho. Mohammadjafari et al. [Mohammadjafari *et al*., 2024] revisam o estado da arte em sistemas que traduzem linguagem natural para SQL, evidenciando que abordagens baseadas em LLMs com *schema linking* e RAG alcançam altas taxas de acerto em benchmarks públicos, mas não abordam canais de entrega conversacionais. Shi et al. [Shi *et al*., 2024] mapeiam as principais estratégias — *prompt engineering*, *fine-tuning* e agentes com ReAct — e discutem desafios como ambiguidade semântica

e SQL incorreto, fornecendo diretrizes para o design do pipeline deste trabalho. Xie et al. [Xie *et al.*, 2025] ampliam o escopo para agentes de análise de dados, descrevendo mecanismos de memória e raciocínio iterativo que inspiram a arquitetura de *function calling* adotada.

No âmbito dos softwares, DB-GPT [Eosphoros AI, 2026], WrenAI [Canner Inc., 2026] e Chat2DB [Chat2DB Inc., 2026] demonstram a viabilidade comercial de assistentes de dados com LLMs, integrando Text-to-SQL, RAG e geração de visualizações. Contudo, nenhum deles oferece integração nativa com aplicativos de mensagens nem prioriza o português brasileiro — lacunas que este trabalho endereça diretamente. A análise comparativa completa está consolidada na Tabela 1 (Apêndice).

3 Metodologia

A pesquisa é classificada como aplicada, de natureza quantitativa e qualitativa, com abordagem experimental. O desenvolvimento segue ciclos iterativos: modelagem do banco sintético, implementação do agente, integração ao mensageiro e avaliação com conjunto de perguntas de validação.

3.1 Proposta de Portfólio

O sistema proposto é um agente conversacional de BI que recebe perguntas em linguagem natural via aplicativo de mensagens, gera automaticamente a consulta SQL correspondente, executa-a sobre o banco de dados e retorna a resposta formatada em linguagem natural em segundos — sem que o gestor precise conhecer SQL ou abrir qualquer dashboard.

O banco de dados sintético será modelado em PostgreSQL com tabelas de clientes, contratos, pedidos, faturamento e indicadores operacionais, refletindo o domínio B2B da Galvitech. Os dados serão gerados por script Python com a biblioteca `Faker`, garantindo diversidade e reprodutibilidade. O agente será implementado com a API da Anthropic (Claude) ou OpenAI (GPT-4o), com *function calling* para as ferramentas `execute_sql` e `get_schema`. A integração com o aplicativo de mensagens utilizará a API do Telegram Bot — gratuita, sem burocracia de aprovação e com biblioteca Python madura (`python-telegram-bot`).

3.1.1 Inovação

A proposta inova em três frentes não cobertas pelos trabalhos relacionados: (i) **canal de mensagens como interface primária** — nenhum software ou artigo analisado utiliza aplicativo de mensagens como canal de acesso ao BI; (ii) **foco no português brasileiro** — todos os sistemas existentes foram projetados para o inglês, enquanto a proposta trata o PT-BR como requisito primário, com *system prompt* e validação em português; e (iii) **base sintética como estratégia de privacidade** — elimina dependência de dados reais e garante conformidade com a LGPD 2019 sem acordos complexos, tornando o projeto completamente reproduzível.

3.2 Arquitetura e Tecnologias

A solução adota uma arquitetura em quatro camadas com comunicação via API RESTful. A camada de interface utiliza a Telegram Bot API, que entrega as mensagens do gestor ao backend por meio de um *webhook* (requisição HTTP `POST` com *payload* JSON) e recebe as respostas via `POST /sendMessage`. O backend, desenvolvido em Python com FastAPI, expõe o *endpoint* REST que recebe o *webhook*, orquestra o fluxo e aciona a camada de agente. O agente comunica-se com o LLM (Claude, via Anthropic API, ou GPT-4o, via OpenAI API) por chamadas HTTPS REST (`POST /v1/messages`), empregando *function calling* para invocar as ferramentas `get_schema` e `execute_sql`. Essas ferramentas acessam a camada de dados — um banco PostgreSQL — por meio do driver `psycopg`, executando consultas restritas a comandos `SELECT`, com *timeout* e limite de linhas por segurança. O *stack* principal é: Python 3.12, FastAPI, `python-telegram-bot`, Anthropic/OpenAI API, PostgreSQL 16 e `Faker` para geração dos dados sintéticos.

4 Resultados Esperados

Ao final do PAC 8, espera-se entregar um sistema funcional com os seguintes resultados mensuráveis: (i) *execution accuracy* superior a 70% sobre um conjunto de 30 a 50 perguntas de validação em português, cobrindo os domínios de vendas, faturamento, pedidos e indicadores operacionais; (ii) tempo médio de resposta ponta a ponta inferior a 10 segundos, demonstrando viabilidade prática para uso gerencial cotidiano; (iii) validação qualitativa positiva com ao menos um gestor da Galvitech, confirmando que as perguntas cobertas e as respostas geradas são relevantes e compreensíveis para o contexto real da empresa.

Como resultado secundário, espera-se produzir um conjunto de dados sintético público, um *system prompt* em português otimizado para o domínio B2B e um protocolo de avaliação de agentes Text-to-SQL em português — contribuições que podem ser reutilizadas por outros pesquisadores.

5 Discussões e Conclusões

O que a proposta resolve: O assistente elimina a barreira de acesso a dados analíticos para gestores não técnicos, entregando informações estratégicas diretamente no canal de comunicação que eles já utilizam no cotidiano. A combinação de *function calling*, Text-to-SQL e interface conversacional em português representa uma contribuição prática para empresas B2B de médio porte que não dispõem de equipes dedicadas de dados.

Desafios esperados: O principal desafio técnico é a geração de SQL correto para perguntas ambíguas ou que envolvam múltiplas tabelas e agregações complexas. LLMs podem gerar SQL sintaticamente válido mas semanticamente incorreto — para mitigar isso, o *system prompt* incluirá exemplos de perguntas e queries corretas (*few-shot prompting*) e o agente validará o resultado antes de responder. Um segundo desafio é a latência: chamadas à API do LLM somadas à execução do SQL podem ultrapassar 10 segundos em picos de carga — o que será monitorado durante os experimentos.

Limitações: O sistema não gerará gráficos ou visualizações — respostas serão exclusivamente textuais. Não haverá *fine-tuning* do modelo, pois exige infraestrutura e dados rotulados fora do escopo de um projeto solo. A validação com a Galvitech será qualitativa, sem acesso a dados reais de produção.

Trabalhos futuros: Extensões naturais incluem gera-

ção de gráficos inline no chat, suporte a mensagens de voz com transcrição automática, autenticação por gestor com controle de acesso a indicadores, e *fine-tuning* do modelo com vocabulário técnico do domínio B2B brasileiro.

Conclusão: A proposta ocupa um espaço ainda não explorado na literatura e no mercado: a democratização do acesso a dados de BI por meio de aplicativos de mensagens, em português, com foco em indicadores operacionais B2B e validado sobre base sintética. Os trabalhos relacionados confirmam a maturidade técnica do Text-to-SQL com LLMs; a inovação está na interface, no idioma e na estratégia de privacidade. O projeto é viável para desenvolvimento solo em um semestre, com escopo bem delimitado e métricas objetivas de avaliação.

Declarações complementares

Contribuições dos autores

Arthur Hassuma identificou o problema junto à empresa parceira Galvitech, concebeu a arquitetura da solução, conduziu a revisão bibliográfica e redigiu integralmente este documento. O autor leu e aprovou a versão final.

Conflitos de interesse

O autor declara não ter qualquer conflito de interesse relacionado a este trabalho.

Disponibilidade de artefatos de pequisa

O código-fonte será mantido em repositório público no GitHub, sob licença MIT, durante todo o ciclo de desenvolvimento. A base de dados utilizada será inteiramente sintética, gerada pelo próprio autor, não contendo dados reais de clientes ou transações. Demais artefatos poderão ser solicitados diretamente ao autor.

Uso de Inteligência Artificial

O modelo Claude (Anthropic) foi utilizado como suporte à revisão gramatical, formatação estrutural e organização do texto deste documento. A concepção técnica — arquitetura do agente, escolha de tecnologias, definição do pipeline, análise bibliográfica e argumentação científica — é de autoria exclusiva do autor, que assume inteira responsabilidade pelo conteúdo do manuscrito.

Outras informações relevantes

Por utilizar exclusivamente dados sintéticos, o projeto não envolve tratamento de dados pessoais, dispensando submissão a comitê de ética. A validação qualitativa com a Galvitech será conduzida sem coleta ou armazenamento de dados operacionais reais.

Referências

Canner Inc. (2026). WrenAI: Open-source GenBI agent. Disponível em: `https://github.com/Canner/WrenAI`. Acesso em março de 2026.

Chat2DB Inc. (2026). Chat2DB: AI-powered SQL and BI tool. Disponível em: `https://chat2db.ai`. Acesso em março de 2026.

Eosphoros AI (2026). DB-GPT: Empowering database interactions with private LLM technology. Disponível em: `https://github.com/eosphoros-ai/DB-GPT`. Acesso em março de 2026.

Golfarelli, M. and Rizzi, S. (2009). *Data Warehouse Design: Modern Principles and Methodologies*. McGraw-Hill, New York.

Guo, J., Zhan, Z., Gao, Y., Xiao, Y., Lou, J.-G., Liu, T., and Zhang, D. (2019). Towards complex text-to-SQL in cross-domain database with intermediate representation. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 4524–4535. DOI: 10.18653/v1/P19-1444.

Mohammadjafari, A., Bogaard, E., and Araujo, R. (2024). From natural language to SQL: Review of LLM-based text-to-SQL systems. Disponível em: `https://arxiv.org/abs/2410.01066`. Acesso em março de 2026.

Shi, P. *et al*. (2024). A survey on employing large language models for text-to-SQL tasks. *ACM Computing Surveys*. DOI: 10.1145/3737873.

Wang, L., Ma, C., Feng, X., Zhang, Z., Yang, H., Zhang, J., Chen, Z., Tang, J., Chen, X., Lin, Y., Zhao, W. X., Wei, Z., and Wen, J.-R. (2024). A survey on large language model based autonomous agents. *Frontiers of Computer Science*, 18(6):186345. DOI: 10.1007/s11704-024-40231-1.

Xie, T. *et al*. (2025). A survey on large language model-based agents for statistics and data science. *The American Statistician*. DOI: 10.1080/00031305.2025.2561140.

Yu, T., Zhang, R., Yang, K., Yasunaga, M., Wang, D., Li, Z., Ma, J., Li, I., Yao, Q., Roman, S., Zhang, Z., and Radev, D. (2018). Spider: A large-scale human-labeled dataset for complex and cross-domain semantic parsing and text-to-SQL task. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 3911–3921. DOI: 10.18653/v1/D18-1425.

Apêndice

Tabela Comparativa

A Tabela 1 evidencia que os doze pontos-chave se distribuem em três grupos. No primeiro, referente às capacidades técnicas já consolidadas — Text-to-SQL com LLM, respostas em linguagem natural e foco em usuários não técnicos —, praticamente todos os trabalhos pontuam, confirmando a maturidade da área. No segundo grupo estão os três diferenciais exclusivos da proposta: integração com aplicativo de mensagens, suporte ao português brasileiro e uso de dados sintéticos para privacidade — linhas em que todos os seis trabalhos analisados apresentam ausência (×) e somente a proposta atende plenamente. Esse é o núcleo de inovação do projeto. No terceiro grupo encontram-se os dois pontos não atendidos pela proposta — *fine-tuning* do modelo e geração de gráficos —, presentes sobretudo nos softwares mais maduros (DB-GPT, WrenAI e Chat2DB), que contam com equipes dedicadas e infraestrutura robusta; sua ausência na proposta é uma decisão consciente de escopo, e ambos integram a agenda de trabalhos futuros. Em síntese, a proposta atende nove dos doze pontos, posicionando-se de forma competitiva frente ao estado da arte e, ao mesmo tempo, ocupando um espaço de inovação não explorado pelos trabalhos relacionados.

Tabela 1. Comparativo entre trabalhos relacionados e a proposta. ✓ atende; ○ parcial; × não atende. A1: Mohammadjafari *et al.*; A2: Xie *et al.*; A3: Shi *et al.*; S1: DB-GPT [Eosphoros AI, 2026]; S2: WrenAI [Canner Inc., 2026]; S3: Chat2DB [Chat2DB Inc., 2026].

Ponto-chave	**A1**	**A2**	**A3**	**S1**	**S2**	**S3**	**Proposta**
Text-to-SQL com LLM	✓	✓	✓	✓	✓	✓	✓
Agente autônomo (func. calling)	○	✓	✓	✓	○	×	✓
Respostas em linguagem natural	✓	✓	✓	✓	✓	✓	✓
Foco em usuários não técnicos	✓	✓	○	✓	✓	✓	✓
Integração com app de mensagens	×	×	×	×	×	×	✓
Suporte ao português brasileiro	×	×	×	○	×	×	✓
Dados sintéticos / privacidade	×	×	×	×	×	×	✓
Avaliação (execution accuracy)	✓	×	✓	×	×	×	✓
Domínio B2B / indic. operac.	×	○	×	○	○	○	✓
Implantação leve (solo dev.)	×	×	×	○	○	✓	✓
Fine-tuning do modelo	×	○	✓	✓	×	×	×
Geração de gráficos	×	○	×	✓	✓	✓	×

Cronograma de Desenvolvimento

O cronograma da Tabela 2 organiza o desenvolvimento em dezesseis semanas, distribuídas em etapas sequenciais e parcialmente sobrepostas. As primeiras semanas concentram-se na revisão bibliográfica e na modelagem e geração da base sintética; o núcleo do projeto — implementação do agente e integração ao aplicativo de mensagens — ocupa a parte central; e as semanas finais destinam-se aos experimentos, à validação com a empresa parceira e à redação e revisão do documento final.

Tabela 2. Cronograma de desenvolvimento em semanas.

Atividade	**S1**	**S2**	**S3**	**S4**	**S5**	**S6**	**S7**	**S8**	**S9**	**S10**	**S11**	**S12**	**S13**	**S14**	**S15**	**S16**
Revisão bibliográfica	•	•														
Modelagem banco sintético		•	•													
Geração dos dados sintéticos			•	•												
Implementação do agente				•	•	•										
Integração ao mensageiro						•	•									
Conjunto de validação (perguntas)							•	•								
Experimentos e avaliação								•	•	•						
Ajustes e iterações										•	•					
Validação com a Galvitech											•	•				
Redação do documento final												•	•	•		
Revisão final e entrega														•	•	•