Assistente Conversacional de BI para autopeças

Telegram → FastAPI → Gemini → PostgreSQL

Top 3 clientes por faturamento em setembro de 2026

Ranking de faturamento emitido
Período: 01/09/2026 a 30/09/2026

1. Peças Floresta — R$ 23.439,00
2. Rota Norte Catarinense Transportes — R$ 19.065,35
3. Peças Santa Cruz — R$ 18.500,55

PAC Extensionista VIII
Arthur Hassuma · 08/11/2026

O problema e a solução

1

O problema

Os números do negócio ficam em relatórios e dependem de alguém para consultá-los.

2

A solução

O gestor pergunta em português no Telegram e recebe o número exato do banco de dados.

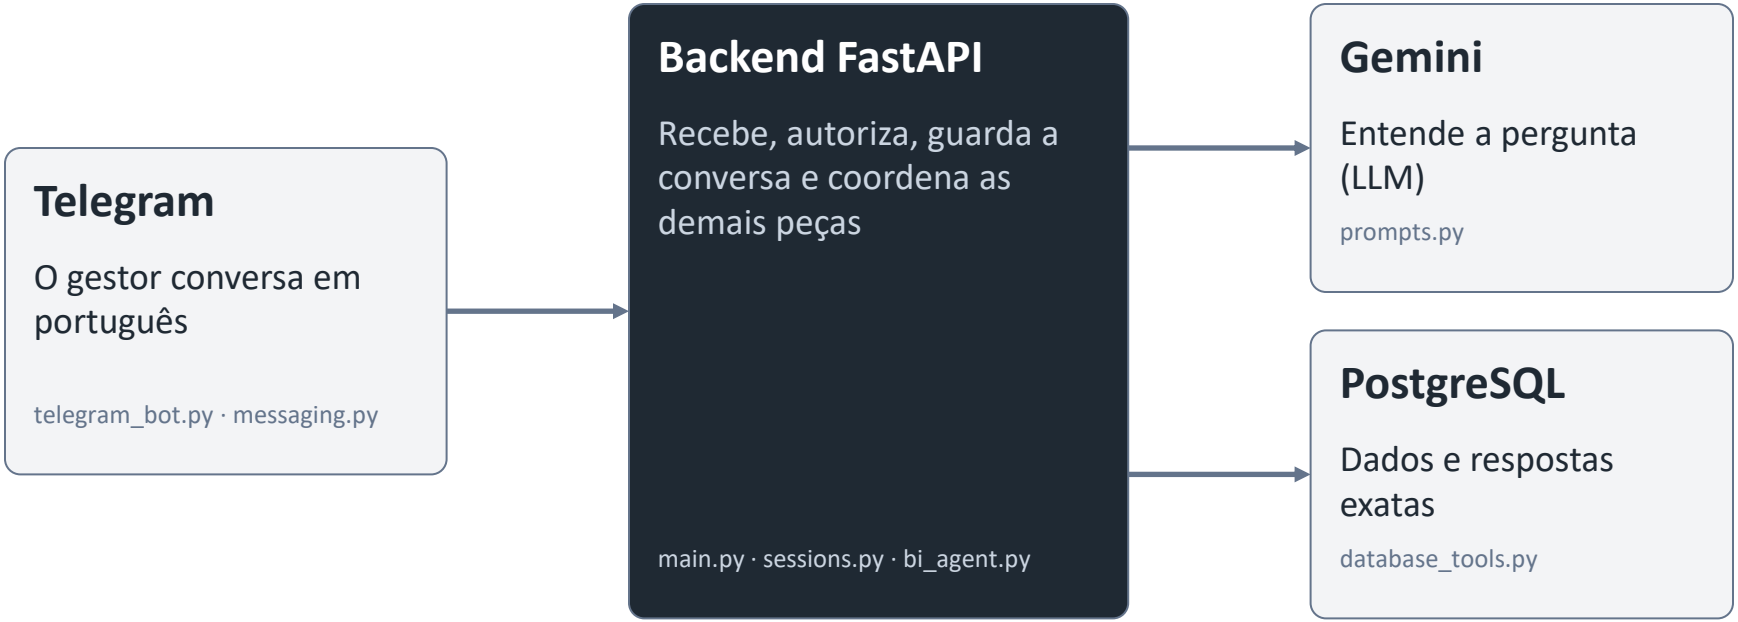
3

A regra de ouro

A IA interpreta a pergunta. O código consulta, valida e escreve a resposta.

Dados 100% sintéticos · sete métricas · tudo em português

Arquitetura em camadas



Roda em Docker numa VM da Oracle · banco sem porta pública · usuário do banco somente leitura

O caminho de uma pergunta

1

Telegram entrega

Polling envia ao webhook

2

Backend confere

Segredo, tamanho e fila

3

Só gestores

IDs autorizados, chat privado

4

Gemini planeja

Plano em JSON, sem SQL

5

Código valida

Datas e período com prova

6

SQL seguro

Modelo fixo ou filtro livre

7

Banco executa

Usuário somente leitura

8

Código responde

Texto com os números do banco

O papel do Gemini (LLM)

O Gemini faz

- Interpreta a pergunta em português
- Devolve um plano em JSON (métrica, medida, período)
- Escreve SQL só em filtros livres, como "só Joinville"

O código faz

- Calcula datas (ontem, ano passado)
- Valida o plano e o SQL
- Executa a consulta no banco
- Escreve a resposta e os números

Usado por API · sem fine-tuning · não gera os números exibidos

Segurança em camadas

1

Autorização

Só gestores autorizados, só chat privado

2

Segredo do webhook

Só o nosso bot entrega mensagens

3

Filtro de SQL

Um SELECT, cinco tabelas, funções permitidas

4

Banco somente leitura

Recusa conectar se houver permissão de escrita

5

Limites

Consulta 3 s · 100 linhas · corpo 64 KiB

6

Logs sem conteúdo

Nenhuma pergunta nem resposta é registrada

O banco e os dados sintéticos

clientes	Oficinas, frotas, lojas, autocenters
contratos	Fornecimento recorrente ou pontual
pedidos	Pedidos de venda de peças
faturamento	Notas fiscais
indicadores_operacionais	Horas de atendimento e pós-venda

100
clientes sintéticos

22
meses de dados

7,7 mil
pedidos de venda

0
dados pessoais reais

Gerado por programa, semente 42: reproduzível e verificável (6 regras de consistência).

Escala de uma revenda pequena-média

	Antes	Depois
Faturamento por mês	R$ 2,4 milhões	**cerca de R$ 400 mil**
Ticket médio do pedido	R$ 8.100	**cerca de R$ 1.200**
Pedidos por cliente (ranking)	todos com 6	**de 7 a 15**
Nome do cliente	Empresa Fictícia 011 …	**Centro Automotivo Itaum**

Respostas mais limpas

Antes

Resumo de pedidos de serviços
Período: 01/10/2026 a 31/10/2026

▸ Valor
• Total: R$ 2.401.621,96

▸ Quantidade
• Quantidade: 295

Depois

Resumo de pedidos de venda
Período: 01/10/2026 a 31/10/2026
Valor: R$ 483.850,40
Quantidade: 386 pedidos

Sem rótulo repetido · sem linhas em branco · unidade junto do valor · ranking sem código interno

Não adivinha: esclarece ou recusa

Qual o faturamento?	Qual período deseja consultar? Informe as datas ou o mês e o ano.	**Pergunta em vez de adivinhar**
Qual o lucro em setembro de 2026?	Não tenho dados de custos para calcular lucro ou margem.	**Recusa honesta**
Faturamento de janeiro até hoje	Período: 01/01/2026 a 08/11/2026 · R$ 4.010.237,73	**Data calculada pelo código**

Uma conversa de verdade

Qual o faturamento?

💬 Qual período deseja consultar? Informe as datas ou o mês e o ano.

Setembro de 2026

📊 Resumo de faturamento emitido
Período: 01/09/2026 a 30/09/2026
Valor: R$ 458.603,80

Montagem a partir de respostas reais do bot; base sintética de autopeças.

Perguntas diretas, com o número do banco

Quantos clientes foram cadastrados em 2023 em cada UF?

📊 Resultado de clientes
Período: 01/01/2023 a 31/12/2023
Medida: quantidade
- UF: SC · Quantidade: 18
- UF: PR · Quantidade: 3
- UF: RS · Quantidade: 2
- UF: SP · Quantidade: 2

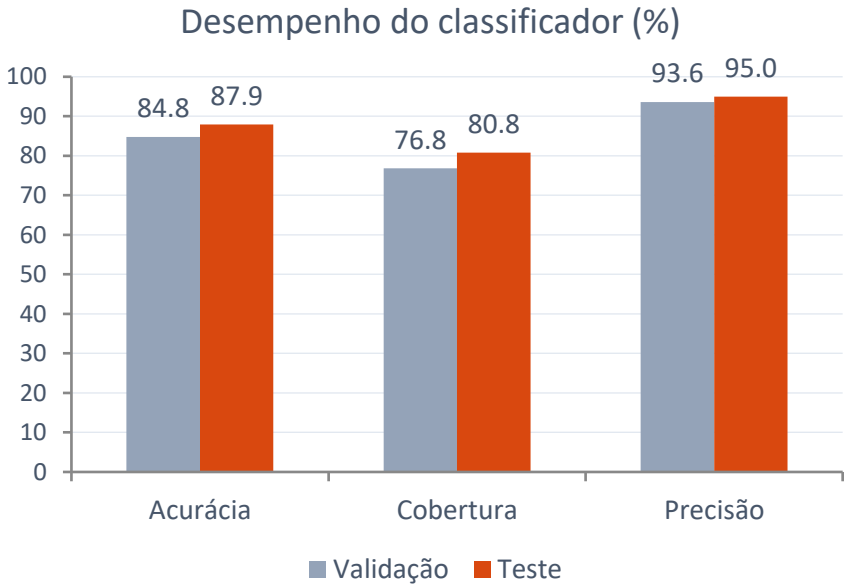
Qual a média de horas realizadas por registro operacional em dezembro de 2025?

📊 Resultado de horas de atendimento
Período: 01/12/2025 a 31/12/2025
Horas realizadas: 11,8971428571428571

Montagem a partir de respostas reais do bot; base sintética de autopeças.

Treinamento: classificador de intenções

- TF-IDF + regressão logística
- 7 intenções: total, comparação, tendência, ranking, segmentação, operacional, genérica
- 1.112 treino · 224 validação · 224 teste, todos sintéticos
- Formas de perguntar do teste nunca aparecem no treino
- Sugere 2 exemplos ao Gemini; não decide nada



O Gemini não foi treinado. Classificar a pergunta não prevê faturamento.

Como garantimos que o teste vale

1

Critério gravado

Antes de treinar

9c8714f

2

Treino e escolha

Só pela validação

emenda registrada

3

Modelo congelado

Antes do teste

4072831

4

Teste, uma vez

Critério atingido

87,9% · 95,0%

Limites declarados

- O ganho nas respostas do bot não foi medido
- Teste sintético, escrito pela mesma equipe
- Classe operacional é a mais fraca (F1 0,67)
- Em 22 perguntas reais: 17 acertos (77%)

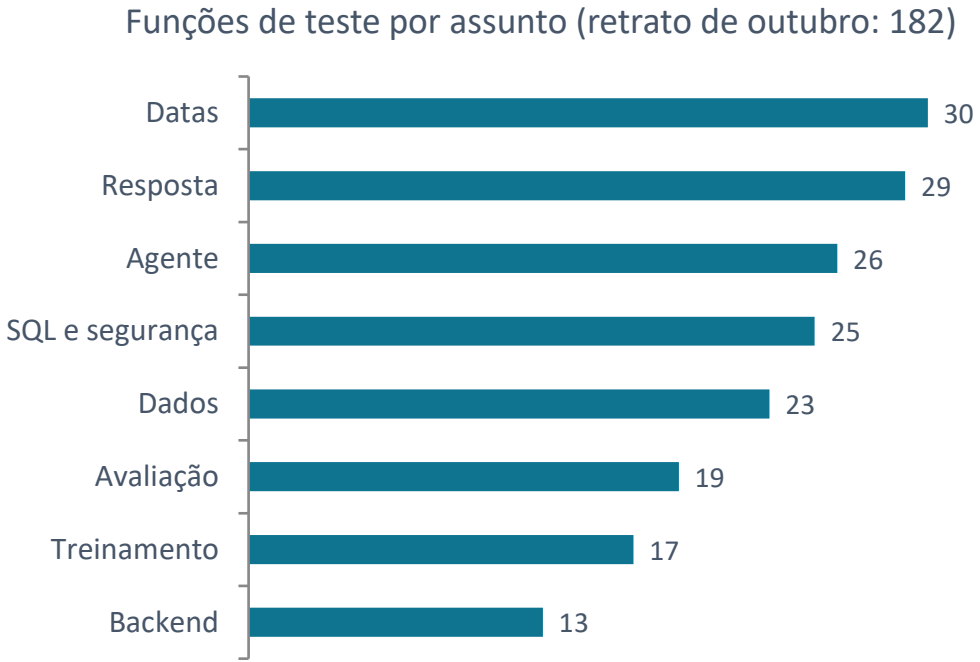
Testes automáticos

285

testes passam; 52 exigem o banco de teste

218

funções de teste, 29 arquivos



Avaliação real com o Gemini (outubro)

20/20
casos de desenvolvimento

20/20
casos reservados (teste)

24/25
casos gerenciais

1,6 s
por turno (agente e banco)

Como ler esses números

- Medem o sistema inteiro (Gemini, modelos e código) em amostra pequena e sintética
- São de outubro, no domínio de software; a medida de novembro (próximo slide) usa outra base e não é comparável
- Cada caso compara a resposta do bot com uma consulta de referência independente

Reavaliação com autopeças (novembro)

12/16
respostas certas, reservado A

6/8
respostas certas, reservado gerencial

13/16
respostas certas, conjunto novo

2,8 s
por turno (agente e banco)

Como ler esses números

- Gemini real; critério (acima de 70%) atendido no limite. 12/16 e 6/8: versão antiga; 13/16: corrigida
- O 16/16 do desenvolvimento não vale; com 20 casos, 12/16 e 13/16 não se distinguem
- Classificador de intenções: sem efeito mensurável (ligado contra desligado)

Conferência no Telegram

Pergunta	Resposta do bot	Gerador
Faturamento em setembro de 2026	R$ 458.603,80	**Confere**
Pedidos em setembro, valor e quantidade	R$ 468.323,95 · 385 pedidos	**Confere**
Ago/2026 comparado com ago/2025	+R$ 21.630,78 · +6,20%	**Confere**
Taxa de resolução em setembro	65,00% (13 de 20)	**Confere**
Faturamento de 01/01 a 08/11/2026	R$ 4.010.237,73	**Confere**

Todos os valores conferem com o gerador, centavo por centavo.

Revisão independente do código

10

achados, todos reproduzidos

6

corrigidos, cada um com teste

O que foi corrigido

- Intervalo com "hoje" virava um dia só
- "Ano passado" comparava o ano inteiro
- Taxa de resolução com 20 casas decimais
- Várias medidas falhavam por tamanho
- CTE podia ler o catálogo do PostgreSQL
- Um update ruim travava o bot

O CI do GitHub não inicia desde 07/11; testes rodados com PostgreSQL local

O desenvolvimento em cinco semanas



Início
Banco real, CI e primeira versão

Avaliação
40 casos, teste reservado, relatório

Gerencial
Comparações, rankings e treino v1

Oracle
Hospedagem e dia exato

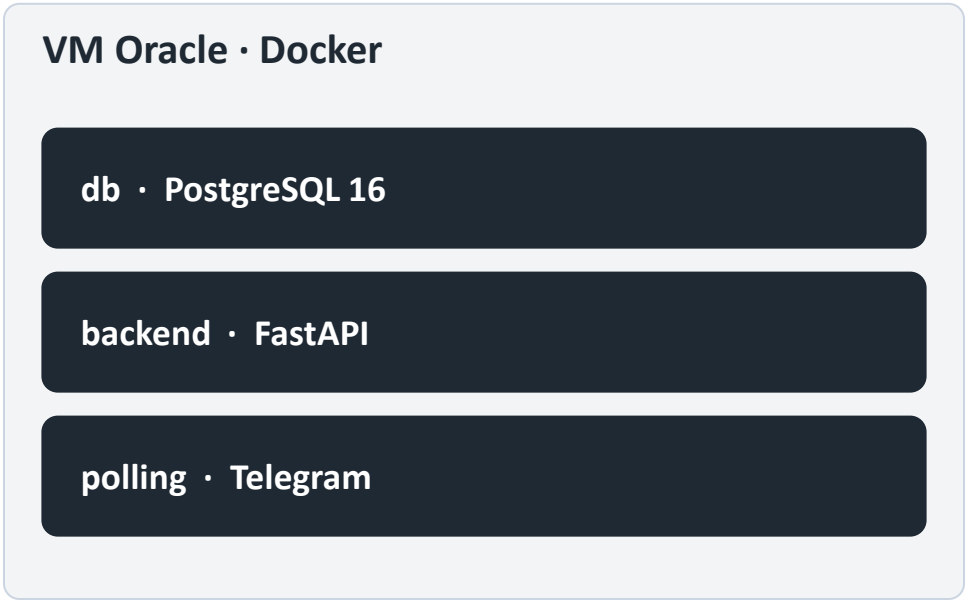
Autopeças
Novo domínio e dados

Revisão
Correções e treino v2

Decisões do autor

Gemini pela cota gratuita · base sintética por causa da LGPD · 40 casos com teste reservado · domínio de autopeças. Código escrito com assistentes de IA, sob direção, revisão e validação do autor.

Em produção na Oracle



Oito rodadas de deploy

- Respostas e perfil de autopeças
- Reseed e defeitos corrigidos
- Ultrareview e classificador v2
- Estado durável (fila e sessões no banco)
- Agente corrigido e rótulos fixos

```
intencao rotulo=ranking confianca=0.99
aceita=True
```

Log do backend depois de uma pergunta feita no Telegram.

Limitações e próximos passos

Limitações

- Resultados no limite: 12/16, 6/8 e 13/16
- Amostras pequenas e sintéticas
- Classificador sem efeito mensurável
- Sem custos: não calcula lucro nem previsão
- CI do GitHub sem iniciar desde 07/11

Próximos passos

- Corrigir o formato do ranking (T08, T48)
- Ampliar a avaliação com mais casos
- Coletar perguntas reais de gestores
- Corrigir o CI na conta do GitHub
- Submeter o relatório e o adendo à instituição

Em resumo

Todo número vem do banco	A IA interpreta; o código consulta e escreve a resposta.
Cada correção tem teste	285 testes passam (52 exigem o banco de teste); os novos falham sem a correção.
Limites declarados	Sintético, amostra pequena, classificador sem efeito mensurável.